




프로젝트 주제	AI 캐릭터와 교감하는 '육성형 채팅 시뮬레이션'
원본 데이터 (나무위키 및 유튜브 영상)	[캐릭터 설명 나무위키] - 탄지로 - 레고쿠 - 이노스케 - 젠이츠 - 아카자 [귀멸의 칼날 전체 시나리오 영상] - 영상
데이터 전처리 과정	[캐릭터 설명 나무위키] ① 캐릭터 나무위키에서 각 캐릭터의 성격, 외모, 작중 행적 항목을 수집 및 이를 LLM 모델이 인식하고 학습에 활용할 수 있도록 항목별로 정리 ② 불필요한 텍스트를 제거하고, 구조화된 형태의 JSON 파일로 변환. 이 과정에서 항목별 키(예: "성격", "외모", "행적")를 통일하여 데이터 일관성을 확보 전처리 과정 ① 제목 추출·필터링 : 크롤링을 통해 Html 구조에서 를 제목으로 뽑고, 빈 값/rfn-각주 제외, 필요 시 선별 ② 본문 수집·정제 : 나무위키 구조 상 모두 같은 키를 사용하여 제목 블록의 다음 형제들을 따라가며 텍스트를 공백 및 불필요한 표현을 정리해 모음 ③ 구조화: 섹션별 {title, content} 리스트로 묶음. [귀멸의 칼날 전체 시나리오 영상] 전처리 과정 ① 오디오 분리 단계 : 발화 단위를 자동으로 감지하기 위해 pyannote.audio 기반의 segmentation을 수행 ② 텍스트 정렬 : 음성과 문장을 동기화하기 위해 WhisperX를 사용하여 word alignment를 수행 ③ 품질 필터링 : 짧은 구간이나 잡음을 제거하기 위해 librosa와 numpy를 사용했으며, duration이 1초 미만이거나 alignment 점수가 0.85 미만인 구간은 제외 ④ 메타데이터 생성 : pandas를 이용해 CSV와 JSON 데이터를 병합하고, 각 샘플에 대해 clip_id, transcript, alignment_score 등의 항목을 포함 ⑤ 검증 : 무작위로 샘플을 추출하여 오디오와 텍스트의 매칭 정확도를 수동으로 점검했다. ⑥ CSV 화 : 각 화자별로 대사(말투 반영)도 STT화하여 csv파일로 정리 그 결과, 총 2,075개의 유효한 TTS 샘플을 확보했으며, 평균 alignment score는 0.954로 나타났다. 모든 과정이 완료된 후 최종 CSV와 JSON 형태의 메타데이터를 저장했다.
DB 사용 용도	[캐릭터 설명 나무위키] ① 기존과 달리 프롬프트로 캐릭터의 성격을 설정하는 것이 아니라 챗봇에서 LLM 모델이 캐릭터의 성격, 외모, 행동 패턴을 이해해 일관성 있는 묘사와 대화 생성하기 위함 ② 사용자들이 캐릭터와 상호 작용할 때 몰입감을 느끼도록 지원 및 대사 톤, 응답 스타일 등을 세밀하게 제어하는 기반 데이터로 활용 [귀멸의 칼날 전체 시나리오 영상] ① TTS 모델 학습 입력용 : 오디오 - 텍스트 페어 데이터로 VITS 또는 CosyVoice 학습에 사용

② LLM 음성 프롬프트용 : 스토리 / 대사 기반 LLM 생성 음성의 기준 데이터셋으로 활용

Mongo DB 구조



```
_id: ObjectId('68f1adaa4aa1946603877713')
character_id: "akaza"
appearance: Object
behavior_patterns: Object
breathing_style: "혈귀술 - 파괴살"
core_values: Array (4)
default_affinity: 100
description: "십이귀월 상현 삼, 강자의 투기를 갈망하는 무술가형 도깨비"
emotional_triggers: Object
name: "아카자"
personality: "obsessive, martial_artist, thrill_seeker, brutal, disciplined"
rank: "상현 삼"
signature_quotes: Array (3)
source_file: "akaza.json"
tone: Object
```