

SK 네트워크 Family AI 과정 15 기

데이터 수집 및 저장 수집 데이터 보고서

산출물 단계	데이터 수집 및 저장
평가 산출물	수집 데이터 보고서
제출 일자	2025-10-02
깃허브 경로	https://github.com/SKNETWORKS-FAMILY-AICAMP/SKN15-FINAL-5TEAM
작성 팀원	조태민

1. 수집 데이터 개요

데이터명	수집 대상	수집 목적	사용 예정 기능	출처/저작권
귀멸의 칼날 캐릭터 음성	62 명 캐릭터	5 명의 캐릭터 목소리 복제(TTS 파인튜닝)	VITS 모델 파인튜닝	비상업적 연구 및 포트폴리오 목적으로 한정 / 상업화 시 IP 라이선스 검토 필수
시나리오 등장 캐릭터 지식 기반 JSON	캐릭터별 나무위키 문서	%Wtext{LLM}의 캐릭터 페르소나 및 지식 기반 구축	LLM 프롬프트 튜닝 및 RAG(검색 증강 생성) 활용	나무위키 크롤링(출처 명시, 비상업적 내부 활용 한정)

2. 수집 방법 및 자동화 절차

- 수집 방식:

○ 기타: 오디오 분리 및 전사 파이프라인(음성) / 웹 크롤링(텍스트)

● 수집 도구 또는 스크립트 설명:

항목	내용
사용한 언어/라이브러리	Python 3.11+yt-dlp,pyannote.audio,WhisperX,FFmpeg-python
자동화 여부 및 주기	수집 및 화자분리, 클립화 파이프라인 자동화(1 회성 실행) 음성 파일은 개발자가 음성을 직접 들으며, speaker 와 캐릭터명을 매핑. 노이즈 제거(전투, 기합 소리 등)
오류 발생 시 예외 처리 전략	RunPod 환경에서 Kernel Restarting(메모리) 오류 발생 시, WhisperX\$Wtext{CLI}\$로 우회 실행하여 GPU 연산 완료

3. 데이터 설명 및 구성

3.1 수집 데이터 예시

	A	B	C	D	E	F	G	H	I	J	K	L	M
1	start	end	speaker_id	text									
2	7.726	31.841	SPEAKER_15	저음 뽕졌습니다... 기부츠지... 무산... 아카사... 왜 이런 일이 일어났는가... 네즈코 죽지마... 죽지마!									
3	31.861	36.808	SPEAKER_07	가족이 헬기에게 살해되기 전... 형님!									
4	37.763	39.606	SPEAKER_48	안녕히 가세요!									
5	39.626	45.053	SPEAKER_16	산지로는 마을에 수출팔로 내려갔었다.									
6	45.414	47.197	SPEAKER_16	와, 산지로야!									
7	47.217	47.517	SPEAKER_07	이런 날에 산으로 내려왔어?									
8	47.537	64.441	SPEAKER_07	그러나 다음날 집에 돌아와 보니 어머니와 동생들은 이미 사망했고... 흠뻑새... 여동생 네즈코만 숨이 붙어									
9	65.883	66.304	SPEAKER_24	네즈코!									
10	66.324	67.245	SPEAKER_24	네즈코만은 아직 따뜻함이 있어.									
11	67.265	67.686	SPEAKER_24	의사에게 보여주면 도움이 될지도 몰라.									
12	69.151	88.762	SPEAKER_07	귀할때 주계급 중 한명인 토미오카 기운은 털기가 된 네즈코를 제거하려 했지만 탄지로가 막아섰다.									
13	88.782	89.282	SPEAKER_24	나제 카바우?									
14	91.646	94.23	SPEAKER_37	오래노 시고토와 오니오 키르코토다.									
15	94.514	103.629	SPEAKER_38	제발... 언니를 죽이지 말아주세요... 생살여남의 권한을 다른 사람에게 잡히지 마세요!									
16	103.649	112.023	SPEAKER_07	다른 헬기들과 달리 인간을 먹지 않고 지키려는 네즈코의 모습을... 네즈코는 다른데... 살려두기로 한다.									
17	112.043	112.143	SPEAKER_07	일어났어?									
18	112.163	118.834	SPEAKER_37	대신 이들을 자신의 스승에게 보내는데... 우로코닥이 사콘지라는 여르신을 찾아라.									
19	118.854	119.796	SPEAKER_25	토미오카 기우에게 말했지만...									
20	122.257	125.362	SPEAKER_25	난 우로코다키 사콘지다.									

 SPEAKER_62_02075.wav

 SPEAKER_62_02074.wav

 SPEAKER_62_01811.wav

 SPEAKER_62_01690.wav

 SPEAKER_62_01357.wav

 SPEAKER_62_00981.wav

 SPEAKER_62_00979.wav

그림 1 TTS 학습 용 데이터

```

1  {
2    "character_name": "렌고쿠 교쥬로",
3    "sections": [
4      {
5        "title": "외모",
6        "content": "애니메이션 원작 위로 솟아있는 짙은 눈썹 과
7      },
8      {
9        "title": "성격",
10       "content": "말을 잘 걸어 줘서 좋아한다. - 토미오카 기유타
11      },
12      {
13        "title": "개요",
14        "content": "귀멸의 칼날 의 등장인물 렌고쿠 교쥬로 의 작

```

그림 2 LLM 페르소나 프롬프트 및 RAG 용 캐릭터 JSON 데이터

3.2 파일 및 필드 설명

파일명 또는 테이블명	필드명	데이터 타입	설명	예시
tts_dataset_clips/	(폴더 구조)	WAV	TTS 학습을 위한 캐릭터별 음성 클립	SPEAKER_01/0001.wav
final_transcription.csv	speaker_id	string	화자 식별 ID(예: SPEAKER_15)	SPEAKER_15
	text	string	WhisperX 전사 결과 텍스트	네즈코 죽지마... 죽지마!
캐릭터별.json	character_name	string	수집된 캐릭터 이름	카마도 탄지로
	sections.title	string	문서 내 목차/섹션 제목	외모, 성격, 개요, 최종선별편
	sections.content	string	섹션별 상세 내용 (크롤링 텍스트)	애니메이션 원작 동생과 비슷하게 이마를 드러낸 앞머리 스타일...

3.3 데이터 양

항목	내용
전체 수집 데이터 건수	오디오 클립 \$Wtext{2,075}\$개 (초기 분할 기준)

	/ JSON 파일 \$Wtext{7}\$개
추출된 고품질 데이터 건수	정제 후 약 500~1000 개 클립 예상/ JSON\$Wtext{81,965}\$자, \$Wtext{36}\$개 섹션

3.4 저장 위치 및 포맷

- 저장 경로: /apps/data/
- 저장 포맷: CSV / JSON / wav
- 인코딩: UTF-8

5. 법적·윤리적 검토

- 개인정보 포함 여부:
 - 포함 [o] 미포함
 - 포함된 경우 필드: 이름, 전화번호, 아이디
- 비식별화 조치 여부:
 - 이름 마스킹 [o] 고유키 대체 [] 기타
- 출처 및 사용권:
 - 공개 여부: [] 공개 [o] 내부사용 한정
 - 라이선스 또는 약관 검토 여부:
- 검토자 및 검토 일자:

- 검토자 : 조태민
- 검토 일자 : 25.10.02

4. 데이터 품질 및 정합성 관리 방안

항목	내용
중복 제거 기준	**start 시간, end 시간, speaker_id**가 모두 동일한 클립은 중복으로 간주하고 제거합니다. (TTS 클립 분할 과정에서 중복은 최소화됨)
정합성 검증 방법	수동 청취 및 CSV 정제를 통해 \$Wtext{WhisperX} 가 생성한**\$Wtexttt{text}\$와 \$Wtexttt{audio}\$의 1:1 매칭**을 확인하고, 매칭되지 않는 클립은 삭제합니다.
Null 처리 및 결측치 전략	text 필드가 \$Wtext{Null}\$이거나 텍스트 길이가 \$Wtext{0}\$인 행, 그리고 \$Wtexttt{duration}\$이 \$Wtext{0.5}\$ 초 미만인 클립은 모두 결측치로 간주하고 삭제합니다.
표준화 전략	텍스트 전처리 여부:TTS 파인튜닝 전, 다음과 같은 표준화를 적용합니다.1. 한글 외 특수문자(예: ?!,) 제거 2. \$Wtext{숫자}\$ 및 영문}\$은 한글로 변환 (예: A4→에이포, 12→열두)

5. 변경 이력 및 보완 내역

변경일	변경자	변경 내용	비고
2025-10-02	조태민	TTS 학습 데이터셋 구축 완료	2,075 클립 생성
2025-10-02	이준원	캐릭터 특성 기반 JSON 크롤링	LLM 페르소나 데이터 확보
2025-10-02	조태민	수집 데이터 스키마 작성	TTS 학습용 / LLM 페르소나용