

[모델링 및 평가] 수집된 데이터 및 전처리 문서

SK Networks Family AI Camp 15기 : Andrew팀

산출물 단계	모델링 및 평가
평가 산출물	수집된 데이터 및 전처리 문서
제출 일자	2025. 10.17
깃허브 경로	https://github.com/SKNETWORKS-FAMILY-AICAMP/SKN15-FINAL-5TEAM
작성 팀원	조태민, 이준원, 권도원

1. 개요

1.1. 데이터 설명

본 문서는 Kimetsu: Mugen-Train 대화형 챗봇에서 Parent/Children Agent가 사용하는 캐릭터 인적사항(JSON) 데이터의 수집·전처리 과정을 정리한다.

데이터는 캐릭터의 이름, 역할, 소속, 인상(appearance), 말투·톤(tone), 에셋 참조(images) 등으로 구성되며, 장면 전환/선택지 로직과 톤·호칭 규칙에 직접 사용된다. 본 문서는 데이터 출처·수집 방법·전처리 단계·품질 관리·저장 방식을 포함한다.

1.2 데이터 수집 목적

- 캐릭터별 말투·톤·호칭 정보를 일관성 있게 관리하여 LLM 응답 안정성 확보
- Parent/Children Agent가 역할/소속/관계/에셋을 신뢰성 있게 참조하도록 스키마 표준화
- 추후 캐릭터 추가 시 회귀 방지(스키마·검증·DQ 리포트 기반)

2. 데이터 수집

2.1 데이터 출처

나무위키 캐릭터 문서(예: 카마도 탄지로, 렌고쿠 교쥬로, 하시바라 이노스케, 아가츠마 젠이츠, 아카자)
라이선스: CC BY-NC-SA 2.0 KR (비영리·동일조건) — 문서 내 출처/라이선스 표기

2.2 데이터 유형

- JSON 구조 텍스트 데이터 (캐릭터별 1파일)

3. 데이터 전처리

3.1 전처리 개요 (전체 흐름도)

- (1) 크롤링
- (2) 문자/공백 정규화(NFC)
- (3) 키 표준화(snake_case)
- (4) 최소 스키마 검증
- (5) 결측치 처리
- (6) 간단 DQ 요약
- (7) (후속) 3→5단계 톤 매핑/자산 참조 검증

3.2 전처리 파이프라인 요약

단계	목적	수행 작업	사용 도구/라이브러리
크롤링	출처 일관화 및 라이선스 준수	나무위키 문서 스냅샷 고정, CC BY-NC-SA 표기, 수집 일자 기록	브라우저/스크립트, 기록 문서
문자/공백 정규화 (NFC)	텍스트 일관화 및 파싱 안정성	유니코드 NFC 통일, 앞뒤 공백 제거, 연속 공백 1칸으로 축약, 제어문자 제거	unicodedata, re
키 표준화 (snake_case)	스키마 일치 및 유지보수 용이성	nameKR→name, camelCase→snake_case 매핑, 누락 키 기본값 설정(aliases=[], assets.images=[])	Python 스크립트
최소 스키마 검증	필수값 보장으로 파이프라인 안정화	id/name/tone.low·mid·high 존재 확인, 문자열/배열 타입 검사, id 정규식 <code>^[a-z0-9_]+\$</code> 확인	jsonschema
결측치 처리	누락값 처리로 모델/엔진 안정성	aliases 빈 배열 대체, images 빈 배열 대체, tone.*.samples 없으면 []로 채움	pandas(옵션), 순수 Python
간단 DQ 요약	품질 가시화 및 회귀 방지	누락/타입불일치/금치어/참조오류 건수 집계, 캐릭터별 결과 테이블 생성, 리포트(md/csv) 저장	Python(판다스), csv/md 출력
(후속) 3→5단계 톤 매핑/자산 참조 검증	친밀도 5버킷·에셋 무결성 확보	low/mid/high→0-200/.../801-1000 매핑 테이블 초안, images_catalog.json 교차검증	파이썬(dict/set), json

3.3 데이터 정제 (규칙 요약)

- 문자 정규화: 유니코드 NFC 고정, 트림, 연속 공백 1칸, 제로폭·제어문자 제거
- 키 표준화: snake_case 통일(nameKR→name), 누락 키 기본값(aliases=[], assets.images=[], tone.*.samples=[])
- id 규칙: `^[a-z0-9_]+$` (예: tanjiro)
- 금칙 토큰(말투): ㅋㅋ, ㅎㅎ, ^^ 등 — 발견 시 DQ 경고 카운트

3.4 원본 데이터 샘플

항목명	형식	설명	예시
id	str(범주형)	캐릭터 식별자 (전역 고유, snake_case, <code>^[a-z0-9_]+\$</code>)	tanjiro
name	str(자유텍스트)	캐릭터 한글명 (문자/공백 정규화)	카마도 탄지로
aliases	array[str(자유텍스트)]	별칭/다른 표기 목록 (중복 없음)	["탄지로"]
role	str(범주형)	역할 구분 (허용: protagonist/ companion/ antagonist/support)	protagonist
affiliation	str(범주형)	소속 (선택 enum 운영 권장)	귀살대
appearance.impression	str(자유텍스트)	외형/인상 요약 (1–120자 권장)	다정하고 성실한 인상
appearance.keywords[]	array[str(범주형)]	성격/특징 키워드 (중복 없음)	["상냥함", "책임감"]
tone.low.style	str(자유텍스트)	낮은 톤 설명 (격식·거리감 등)	격식 있고 조심스러운
tone.mid.style	str(자유텍스트)	중간 톤 설명	정중하고 따뜻한
tone.high.style	str(자유텍스트)	높은 톤 설명	친근하고 격려하는
tone.low.samples[]	array[str(자유텍스트)]	낮은 톤 예시 대사(0–5개)	["...합니다", "...하겠습니다"]
tone.mid.samples[]	array[str(자유텍스트)]	중간 톤 예시 대사	["...해요", "...할게요"]
tone.high.samples[]	array[str(자유텍스트)]	높은 톤 예시 대사	["...하자!", "...해보자!"]
assets.images[]	array[str(범주형)]	이미지 레퍼런스 ID (카탈로그와 일치 필수)	["scene5_rengoku_arrival_01"]
is_active	bool(선택)	사용/비사용 플래그	TRUE
priority	int(선택)	우선순위(정렬용)	10
similarity_weight	float(선택)	추천/매칭 가중치	0.75
updated_at	date(선택)	ISO 날짜 또는 datetime	2025-10-17

3.5 최소 스키마 (요약)

- required: ["id", "name", "tone.low", "tone.mid", "tone.high"]
- role enum: protagonist|companion|antagonist|support
- assets.images[]는 images_catalog.json과 교차검증(후속 단계)

3.6 형식 변환 (운영/학습 검용)

- 운영용 마스터: characters_db.clean.json
- 학습/평가 검용: 캐릭터×친밀도버킷 JSONL (예: character_id, affinity_bucket, tone_text, sample_utterance)

예시(JSONL 1행):
<pre>{ "character_id": "tanjiro", "affinity_bucket": "601_800", "tone_text": "친근하고 격려하는", "sample_utterance": "괜찮아요. 함께 해보지요!" }</pre>

3.7 학습·평가 데이터 분할

- 장면/대사 샘플 생성 후 Train 80% / Test 20% 권장(캐릭터·장면이 섞이도록 random split)

3.8 데이터 검증 (Case Test)

- 목표: Parent/Children Agent가 role/affiliation/tone을 정확히 참조하는지 케이스 테스트
- 테스트 예:
 - 입력: “丁 — 공손하게 말해줘(탄지로)” → 출력: tone.low.style/mid.style 범위 어투 확인
 - 선택지 전환 시 assets.images[] ID 참조 유효성 확인
- 결론(예): 필수키 검증 통과, 톤 적용 정상, 이미지 참조 미존재 2건 리포트

4. 향후 사용 계획

- 친밀도 5버킷 톤 파생: low/mid/high → 0-200/201-400/401-600/601-800/801-1000 매핑 반영
- 자산 무결성 자동검증: assets.images[] ↔ images_catalog.json 교차검증 스크립트/CI 파이프라인 연결
- 데이터 버전 관리: data/characters/v1.0.0/ 디렉토리 구조로 정제본·DQ 리포트·검증 로그 커밋
- 확장: 캐릭터 추가, 호칭/금칙어 룰 테이블 외부화(노션/CSV→JSON 변환 배치), 회귀 테스트

부록

- 라이선스/표기(보고서 본문·표/그림 캡션에 병기)

출처	라이선스	가공 내역	수집일
나무위키	CC BY-NC-SA 2.0 KR	형식 통일(NFC), 키 표준화·요약 발췌	2025-10-01